Studi Kasus Terpadu Data Mining

Sausan Asma' Mufiidah - J0403241100

2026-06-18

Contents

EDA amesHousing **2**

1. Memuat Dataset . . . 2
2. Memahami Struktur Data . . . 2
3. Missing Value Analysis . . . 6
4. Statistik Deskriptif . . . 6
5. Distribusi Harga Rumah . . . 7
6. Boxplot Harga Rumah . . . 8
8. Korelasi Variabel Numerik . . . 9
9. Variabel Paling Berkorelasi dengan Harga Rumah . . . 10
10. Hubungan Luas Rumah dan Harga Rumah . . . 11
11. Harga Rumah Berdasarkan Kualitas Bangunan . . . 12
12. Persiapan untuk Klastering (Standardisasi) . . . 13
13. Menentukan Jumlah Cluster (Optimasi K: Elbow vs Silhouette) . . . 14

Menggabungkan kedua grafik secara horizontal **14**

14. Persiapan Klasifikasi (Target Engineering) . . . 14
14. Persiapan Klasifikasi (Target Engineering 3 Kelas) . . . 15

3. Fase Pemodelan (Machine Learning) **15**

15. Model 1: Segmentasi Pasar (K-Means Clustering) . . . 16

Profiling Cluster . . . 17

Profiling dan Interpretasi Cluster . . . 17

Simulasi Hasil Segmentasi Pasar (K-Means di Lapangan) . . . 18

16. Model 2: Prediksi Harga Jual (Multiple Linear Regression) . . . 19

Evaluasi Performa Model Regresi Linear . . . 22

Performa ini menunjukkan kemampuan generalisasi yang baik pada data uji, tetapi hasil prediksi tetap dipengaruhi oleh faktor lain di luar fitur yang digunakan. . . . 22

Simulasi Prediksi di Lapangan (Real-World Inference) . . . 22

17. Model 3: Klasifikasi Kelas Harga (Decision Tree) 23
Simulasi Klasifikasi Kelas Properti (Decision Tree di Lapangan) 25

4. Kesimpulan & Insight Global (Executive Summary) 27

1. Sintesis Temuan EDA dan Hasil Pemodelan 27
2. Evaluasi Tiga Model Machine Learning 28
3. Insight dan Implikasi Analisis 28

EDA amesHousing

Bagian ini menyajikan tinjauan analitis terhadap dataset Ames Housing. Eksplorasi berfokus pada identifikasi pola distribusi, penanganan anomali, dan ekstraksi wawasan prediktif sebelum data disalurkan ke dalam pemodelan prediktif maupun segmentasi.

1. Memuat Dataset

Dataset dimuat ke dalam *environment* analisis menggunakan pustaka `AmesHousing`. Integrasi pustaka analitik inti disiapkan untuk mendukung manipulasi matriks dan visualisasi data.

```
# Pustaka Inti & Manipulasi Data
library(AmesHousing)
library(tidyverse)   # Ekosistem manipulasi dan visualisasi
library(caret)       # Framework ML
library(rpart)       # Algoritma Klasifikasi
library(rpart.plot)  # Visualisasi Tree
library(cluster)     # Algoritma Klastering
library(factoextra)  # Evaluasi Klastering
library(gridExtra)
library(corrplot)
library(cluster)
# Memuat dataset mentah
ames_raw <- make_ames()
```

2. Memahami Struktur Data

Langkah pertama dalam pemahaman data adalah menginspeksi dimensi, tipe data, dan sampel observasi dari dataset mentah sebelum manipulasi apa pun dilakukan. Hal ini esensial untuk memetakan arsitektur informasi asli.

```
# 2.1 Inspeksi Volume Data
cat("Dimensi awal dataset mentah: ", dim(ames_raw)[1], "observasi & ", dim(ames_raw)[2], "fitur.\n\n")
```

```
## Dimensi awal dataset mentah:  2930 observasi &  81 fitur.
```

```
# 2.2 Tinjauan Tipe Data (Menampilkan 8 kolom pertama sebagai sampel struktural)
str(ames_raw[, 1:8])
```

```
## tibble [2,930 x 8] (S3: tbl_df/tbl/data.frame)
##  $ MS_SubClass : Factor w/ 16 levels "One_Story_1946_and_Newer_All_Styles",..: 1 1 1 1 6 6 12 12 12 (
##  $ MS_Zoning   : Factor w/ 7 levels "Floating_Village_Residential",..: 3 2 3 3 3 3 3 3 3 3 ...
##  $ Lot_Frontage: num [1:2930] 141 80 81 93 74 78 41 43 39 60 ...
##  $ Lot_Area    : int [1:2930] 31770 11622 14267 11160 13830 9978 4920 5005 5389 7500 ...
##  $ Street      : Factor w/ 2 levels "Grvl","Pave": 2 2 2 2 2 2 2 2 2 2 ...
##  $ Alley       : Factor w/ 3 levels "Gravel","No_Alley_Access",..: 2 2 2 2 2 2 2 2 2 2 ...
##  $ Lot_Shape   : Factor w/ 4 levels "Regular","Slightly_Irregular",..: 2 1 2 1 2 2 1 2 2 1 ...
##  $ Land_Contour: Factor w/ 4 levels "Bnk","HLS","Low",..: 4 4 4 4 4 4 4 2 4 4 ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   Order = col_integer(),
##   ..   PID = col_character(),
##   ..   `MS SubClass` = col_character(),
##   ..   `MS Zoning` = col_character(),
##   ..   `Lot Frontage` = col_integer(),
##   ..   `Lot Area` = col_integer(),
##   ..   Street = col_character(),
##   ..   Alley = col_character(),
##   ..   `Lot Shape` = col_character(),
##   ..   `Land Contour` = col_character(),
##   ..   Utilities = col_character(),
##   ..   `Lot Config` = col_character(),
##   ..   `Land Slope` = col_character(),
##   ..   Neighborhood = col_character(),
##   ..   `Condition 1` = col_character(),
##   ..   `Condition 2` = col_character(),
##   ..   `Bldg Type` = col_character(),
##   ..   `House Style` = col_character(),
##   ..   `Overall Qual` = col_integer(),
##   ..   `Overall Cond` = col_integer(),
##   ..   `Year Built` = col_integer(),
##   ..   `Year Remod/Add` = col_integer(),
##   ..   `Roof Style` = col_character(),
##   ..   `Roof Matl` = col_character(),
##   ..   `Exterior 1st` = col_character(),
##   ..   `Exterior 2nd` = col_character(),
##   ..   `Mas Vnr Type` = col_character(),
##   ..   `Mas Vnr Area` = col_integer(),
##   ..   `Exter Qual` = col_character(),
##   ..   `Exter Cond` = col_character(),
##   ..   Foundation = col_character(),
##   ..   `Bsmt Qual` = col_character(),
##   ..   `Bsmt Cond` = col_character(),
##   ..   `Bsmt Exposure` = col_character(),
##   ..   `BsmtFin Type 1` = col_character(),
##   ..   `BsmtFin SF 1` = col_integer(),
##   ..   `BsmtFin Type 2` = col_character(),
##   ..   `BsmtFin SF 2` = col_integer(),
##   ..   `Bsmt Unf SF` = col_integer(),
##   ..   `Total Bsmt SF` = col_integer(),
##   ..   Heating = col_character(),
##   ..   `Heating QC` = col_character(),
##   ..   `Central Air` = col_character(),
```

```
##   ..   Electrical = col_character(),
##   ..   `1st Flr SF` = col_integer(),
##   ..   `2nd Flr SF` = col_integer(),
##   ..   `Low Qual Fin SF` = col_integer(),
##   ..   `Gr Liv Area` = col_integer(),
##   ..   `Bsmt Full Bath` = col_integer(),
##   ..   `Bsmt Half Bath` = col_integer(),
##   ..   `Full Bath` = col_integer(),
##   ..   `Half Bath` = col_integer(),
##   ..   `Bedroom AbvGr` = col_integer(),
##   ..   `Kitchen AbvGr` = col_integer(),
##   ..   `Kitchen Qual` = col_character(),
##   ..   `TotRms AbvGrd` = col_integer(),
##   ..   Functional = col_character(),
##   ..   Fireplaces = col_integer(),
##   ..   `Fireplace Qu` = col_character(),
##   ..   `Garage Type` = col_character(),
##   ..   `Garage Yr Blt` = col_integer(),
##   ..   `Garage Finish` = col_character(),
##   ..   `Garage Cars` = col_integer(),
##   ..   `Garage Area` = col_integer(),
##   ..   `Garage Qual` = col_character(),
##   ..   `Garage Cond` = col_character(),
##   ..   `Paved Drive` = col_character(),
##   ..   `Wood Deck SF` = col_integer(),
##   ..   `Open Porch SF` = col_integer(),
##   ..   `Enclosed Porch` = col_integer(),
##   ..   `3Ssn Porch` = col_integer(),
##   ..   `Screen Porch` = col_integer(),
##   ..   `Pool Area` = col_integer(),
##   ..   `Pool QC` = col_character(),
##   ..   Fence = col_character(),
##   ..   `Misc Feature` = col_character(),
##   ..   `Misc Val` = col_integer(),
##   ..   `Mo Sold` = col_integer(),
##   ..   `Yr Sold` = col_integer(),
##   ..   `Sale Type` = col_character(),
##   ..   `Sale Condition` = col_character(),
##   ..   SalePrice = col_integer()
##   .. )
```

```
# 2.3 Mengintip Beberapa Baris Pertama Data Mentah
head(ames_raw[, 1:8], 5)
```

```
## # A tibble: 5 x 8
##   MS_SubClass             MS_Zoning Lot_Frontage Lot_Area Street Alley Lot_Shape
##   <fct>                   <fct>            <dbl>    <int> <fct>  <fct> <fct>
## 1 One_Story_1946_and_New~ Resident~          141    31770 Pave   No_A~ Slightly~
## 2 One_Story_1946_and_New~ Resident~           80    11622 Pave   No_A~ Regular
## 3 One_Story_1946_and_New~ Resident~           81    14267 Pave   No_A~ Slightly~
## 4 One_Story_1946_and_New~ Resident~           93    11160 Pave   No_A~ Regular
## 5 Two_Story_1946_and_New~ Resident~           74    13830 Pave   No_A~ Slightly~
## # i 1 more variable: Land_Contour <fct>
```

Keputusan Analitik (Reduksi Dimensi Awal): Berdasarkan inspeksi struktural di atas, ditemukan bahwa dataset memiliki 82 dimensi bervariasi. Memproses seluruh variabel secara simultan sejak awal akan menyebabkan *visual noise* yang tinggi pada analisis missing value (Poin 3) dan statistik deskriptif (Poin 4).

Oleh karena itu, dilakukan pembatasan ruang lingkup (*data reduction*) untuk menyaring data ke dalam format fungsional (`ames_clean`) yang hanya berisi fitur-fitur penggerak utama nilai properti. Di tahap ini pula dilakukan standardisasi penamaan kolom menjadi *snake_case* dan rekayasa metrik operasional (`house_age`, `total_bathrooms`, `total_sqft`) untuk menyederhanakan representasi data.

```
ames_clean <- ames_raw %>%
  mutate(
    Overall_Qual_Num = as.numeric(Overall_Qual),
    House_Age = Year_Sold - Year_Built,
    Total_Bathrooms = Full_Bath + (0.5 * Half_Bath) +
                      Bsmt_Full_Bath + (0.5 * Bsmt_Half_Bath),
    Total_SqFt = Gr_Liv_Area + Total_Bsmt_SF
  )
# cek feature engineering
cor_before <- cor(
  ames_clean$Sale_Price,
  ames_clean$Full_Bath,
  use = "complete.obs"
)

cor_after <- cor(
  ames_clean$Sale_Price,
  ames_clean$Total_Bathrooms,
  use = "complete.obs"
)

cor_before
```

```
## [1] 0.5456039
```

```
cor_after
```

```
## [1] 0.636175
```

```
  # 2. Seleksi Fitur Prioritas
 ames_clean <- ames_clean %>%
   select(
    Sale_Price,
    Neighborhood,
    Overall_Qual_Num,
    Total_SqFt,
    House_Age,
    Garage_Area,
    Total_Bathrooms,
    Kitchen_Qual,
    Central_Air
  ) %>%

  # 3. Standardisasi Penamaan Kolom menjadi snake_case
```

```
  rename_with(~ str_replace_all(tolower(.), " ", "_")) %>%

  # 4. Standardisasi Teks pada Isi Data Kategorikal
  mutate(across(
    where(is.factor) | where(is.character),
    ~ as.factor(str_replace_all(tolower(as.character(.)), "[ /\\-]", "_"))
  )) %>%

  # 5. Pembersihan Data (Sanitasi Missing Values)
  drop_na()

cat("Dimensi pasca-rekayasa dan reduksi: ", dim(ames_clean)[1], "observasi & ", dim(ames_clean)[2], "fi
```

```
## Dimensi pasca-rekayasa dan reduksi:  2930 observasi &  9 fitur analitik.
```

```
cat("Dimensi dataset fungsional untuk analisis lanjut: ", dim(ames_clean)[1], "baris & ", dim(ames_clea
```

```
## Dimensi dataset fungsional untuk analisis lanjut:  2930 baris &  9 kolom.
```

3. Missing Value Analysis

Pemeriksaan integritas data (*missing value analysis*) merupakan prosedur standar untuk memastikan stabilitas algoritma analitik pada tahapan selanjutnya.

```
# Kalkulasi observasi kosong pada fitur terpilih
na_counts <- colSums(is.na(ames_clean))
cat("Jumlah observasi kosong (Missing Values):\n")
```

```
## Jumlah observasi kosong (Missing Values):
```

```
print(na_counts[na_counts > 0])
```

```
## named numeric(0)
```

```
# Pembersihan data dari anomali kosong
ames_clean <- ames_clean %>% drop_na()
cat("\nDimensi data setelah pembersihan: ", nrow(ames_clean), "observasi siap diproses.\n")
```

```
##
## Dimensi data setelah pembersihan:  2930 observasi siap diproses.
```

4. Statistik Deskriptif

Ekstraksi statistik deskriptif dilakukan untuk memetakan tendensi sentral dan dispersi pada variabel numerik inti. Langkah ini krusial untuk mendeteksi keberadaan *outliers* secara parametrik.

```
# Menampilkan ringkasan statistik khusus untuk variabel numerik
ames_clean %>%
  select(where(is.numeric)) %>%
  summary()
```

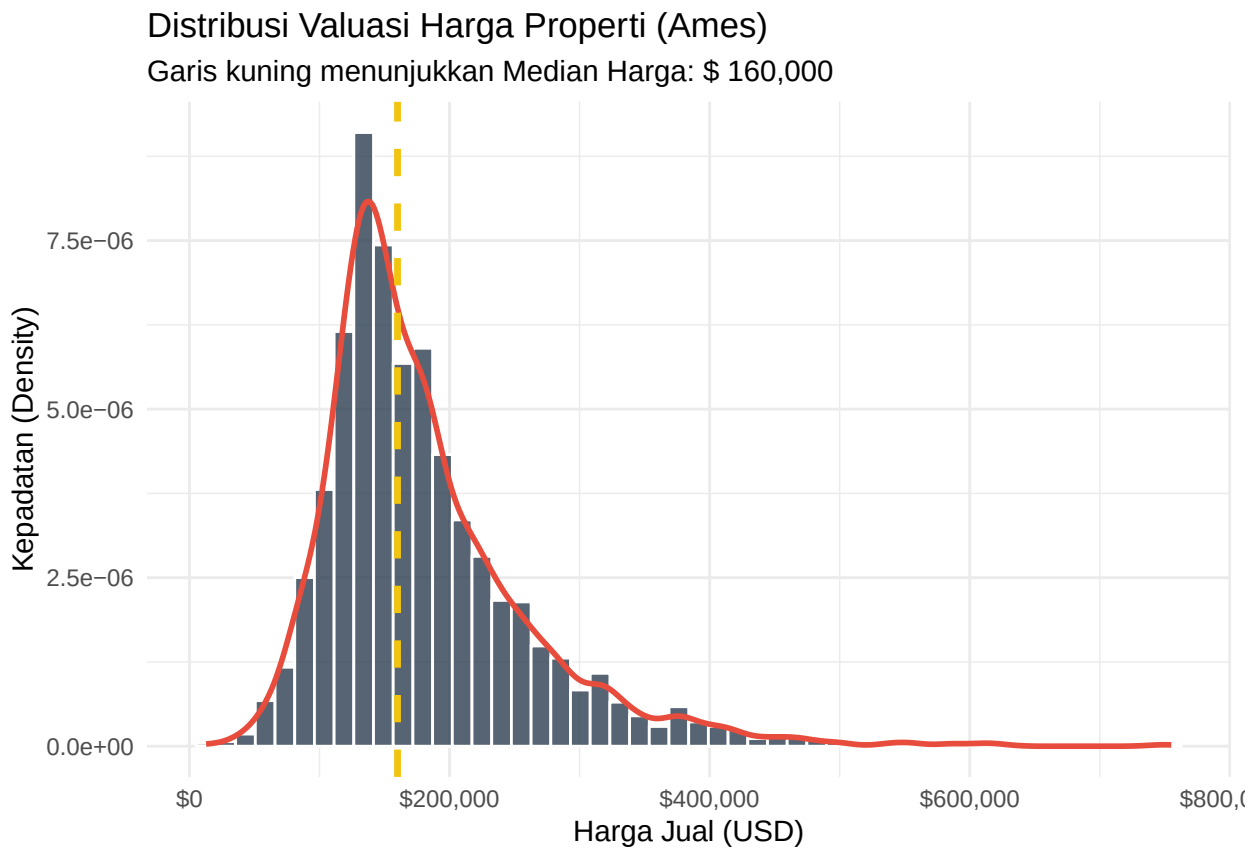
```
##    sale_price     overall_qual_num   total_sqft      house_age
##  Min.   : 12789   Min.   : 1.000   Min.   :  334   Min.   : -1.00
##  1st Qu.:129500   1st Qu.: 5.000   1st Qu.: 2004   1st Qu.:  7.00
##  Median :160000   Median : 6.000   Median : 2452   Median : 34.00
##  Mean   :180796   Mean   : 6.095   Mean   : 2551   Mean   : 36.43
##  3rd Qu.:213500   3rd Qu.: 7.000   3rd Qu.: 2994   3rd Qu.: 54.00
##  Max.   :755000   Max.   :10.000   Max.   :11752   Max.   :136.00
##   garage_area     total_bathrooms
##  Min.   :   0.0   Min.   :1.000
##  1st Qu.: 320.0   1st Qu.:1.500
##  Median : 480.0   Median :2.000
##  Mean   : 472.7   Mean   :2.218
##  3rd Qu.: 576.0   3rd Qu.:2.500
##  Max.   :1488.0   Max.   :7.000
```

5. Distribusi Harga Rumah

Eksplorasi target variabel (`sale_price`) adalah langkah fundamental untuk memahami demografi pasar. Pendekatan visual menggunakan histogram yang dilengkapi dengan kurva kepadatan (*density curve*) dan garis median diaplikasikan untuk melihat titik sentral valuasi.

```
# Kalkulasi median untuk garis referensi
median_val <- median(ames_clean$sale_price)

ggplot(ames_clean, aes(x = sale_price)) +
  # Menggunakan density agar seimbang dengan kurva
  geom_histogram(aes(y = after_stat(density)), bins = 50, fill = "#2C3E50", color = "white", alpha = 0.8
  geom_density(color = "#E74C3C", linewidth = 1) +
  geom_vline(xintercept = median_val, linetype = "dashed", color = "#F1C40F", linewidth = 1.2) +
  scale_x_continuous(labels = scales::dollar_format()) +
  theme_minimal() +
  labs(
    title = "Distribusi Valuasi Harga Properti (Ames)",
    subtitle = paste("Garis kuning menunjukkan Median Harga: $", format(median_val, big.mark=",")),
    x = "Harga Jual (USD)",
    y = "Kepadatan (Density)"
  )
```

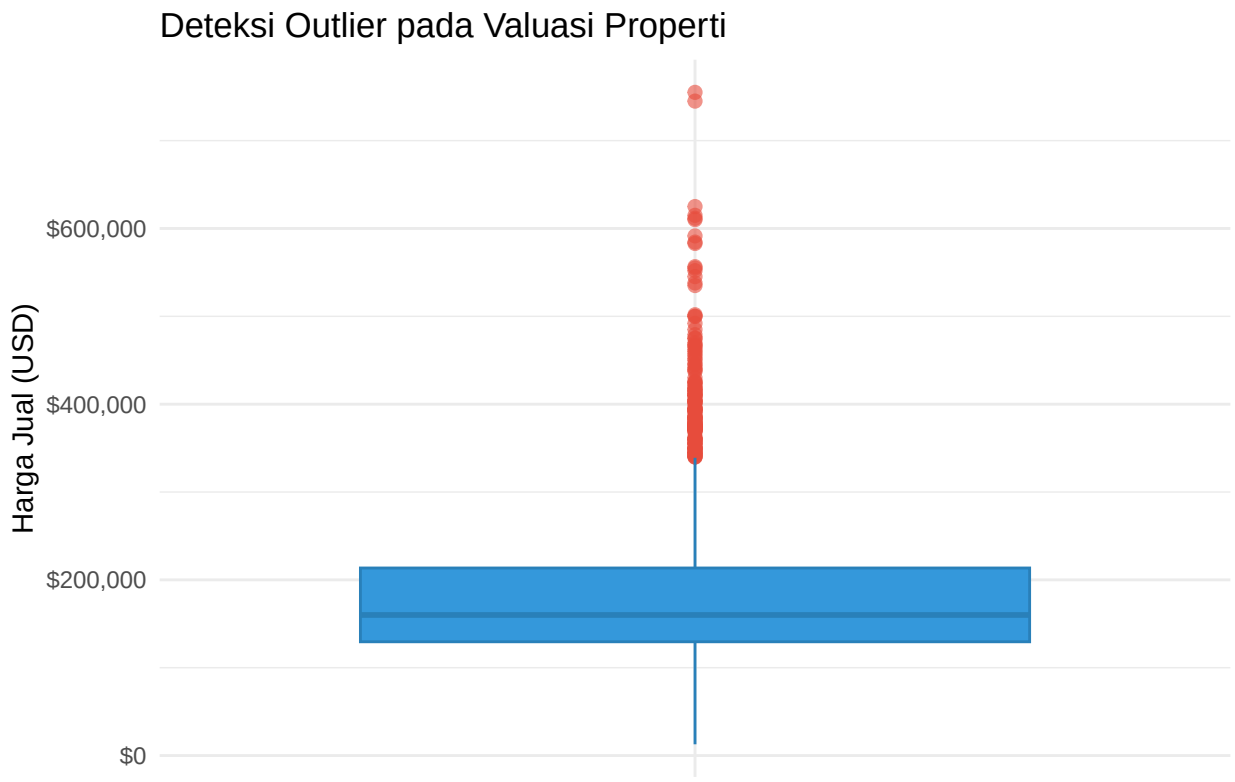


Insight Bisnis: Distribusi harga menunjukkan pola *right-skewed* (miring ke kanan), yang menunjukkan bahwa sebagian besar properti berada pada rentang harga lebih rendah dibandingkan beberapa properti dengan nilai sangat tinggi. Kondisi ini menyebabkan nilai rata-rata harga dapat terdorong oleh keberadaan properti dengan harga ekstrem.

6. Boxplot Harga Rumah

Guna mengidentifikasi persebaran kuartil dan mendeteksi keberadaan anomali matematis (*outliers*) pada harga jual, *Boxplot* dieksekusi secara univariat.

```
ggplot(ames_clean, aes(y = sale_price, x = "")) +
  geom_boxplot(fill = "#3498DB", color = "#2980B9", outlier.color = "#E74C3C", outlier.size = 2, outlie
  scale_y_continuous(labels = scales::dollar_format()) +
  theme_minimal() +
  labs(
    title = "Deteksi Outlier pada Valuasi Properti",
    x = "",
    y = "Harga Jual (USD)"
  )
```



Insight Bisnis: Titik-titik yang berada di luar batas *upper whisker* menunjukkan observasi dengan nilai harga yang relatif tinggi dibandingkan mayoritas data. Observasi tersebut dapat merepresentasikan properti dengan karakteristik khusus atau segmen harga premium.

(Catatan Analitik: Poin 7 diabaikan sesuai dengan spesifikasi referensi kerangka kerja).

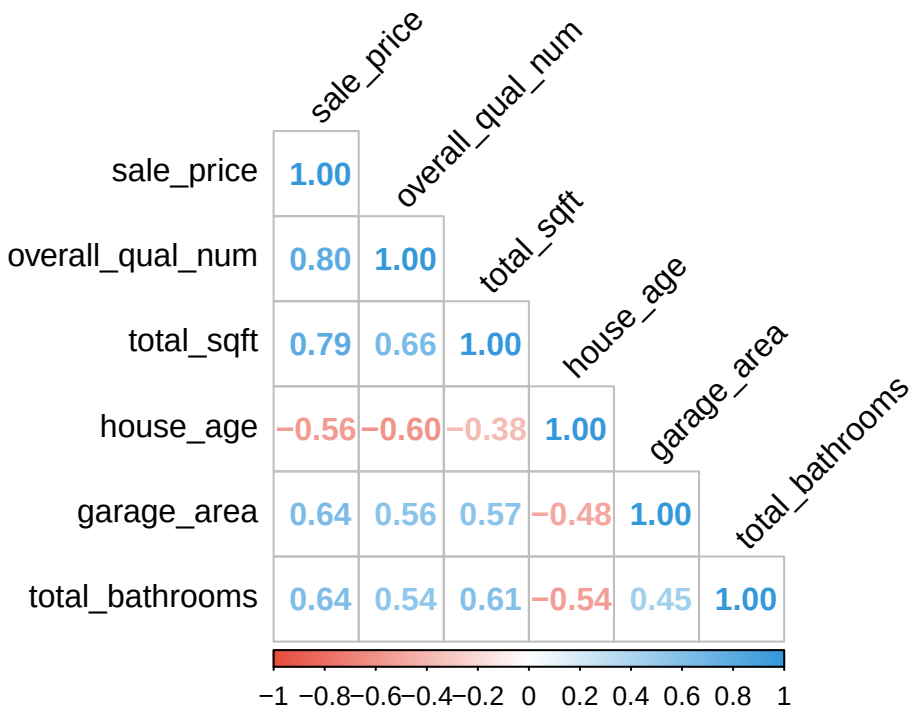
8. Korelasi Variabel Numerik

Analisis korelasi Pearson diaplikasikan untuk mengkuantifikasi kekuatan dan arah hubungan linear antar fitur numerik kuantitatif.

```
# Isolasi khusus untuk fitur numerik
num_vars <- ames_clean %>%
  select(where(is.numeric))

# Kalkulasi matriks korelasi
cor_matrix <- cor(num_vars, use = "complete.obs")

# Visualisasi matriks
corrplot(cor_matrix,
         method = "number",
         type = "lower",
         tl.col = "black",
         tl.srt = 45,
         col = colorRampPalette(c("#E74C3C", "white", "#3498DB"))(200),
         title = "Matriks Korelasi Fitur Kuantitatif",
         mar = c(0,0,2,0))
```



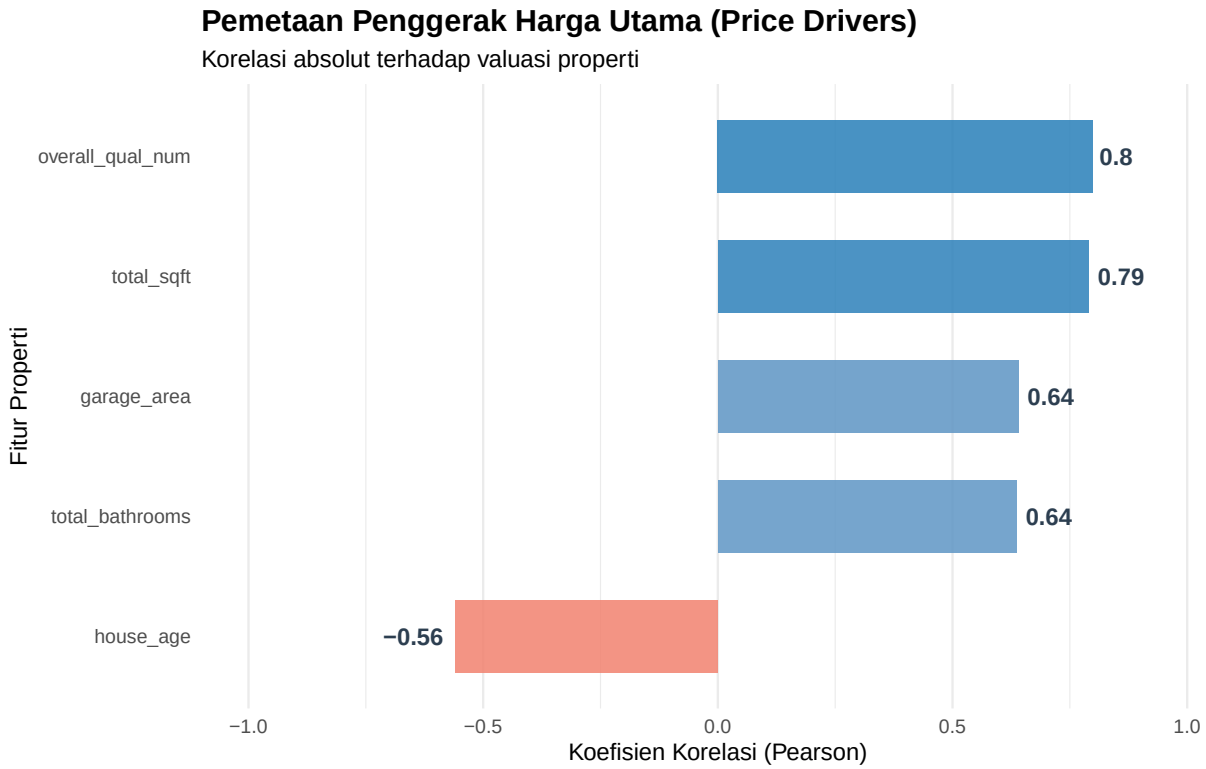
9. Variabel Paling Berkorelasi dengan Harga Rumah

Menyajikan tabel angka seringkali membebani beban kognitif audiens. Sebagai gantinya, vektor korelasi diekstraksi secara spesifik terhadap target `sale_price` dan dipetakan secara visual menggunakan pemeringkatan spasial dan gradasi warna.

```
# Ekstraksi dan pembersihan metrik
cor_with_price <- as.data.frame(as.table(cor_matrix[,"sale_price"])) %>%
  rename(Metrik = Var1, Koefisien = Freq) %>%
  filter(Metrik != "sale_price")

# Visualisasi Minimalis Berdampak Tinggi (High-Performance Visual)
ggplot(cor_with_price, aes(x = reorder(Metrik, Koefisien), y = Koefisien, fill = Koefisien)) +
  geom_col(alpha = 0.85, width = 0.6) +
  # Menambahkan label angka di ujung balok
  geom_text(aes(label = round(Koefisien, 2)),
            hjust = ifelse(cor_with_price$Koefisien > 0, -0.2, 1.2),
            size = 4, fontface = "bold", color = "#2C3E50") +
  # Gradasi warna: Merah (Negatif) ke Biru (Positif)
  scale_fill_gradient2(low = "#E74C3C", mid = "#ECF0F1", high = "#2980B9", midpoint = 0) +
  scale_y_continuous(limits = c(-1, 1)) +
  coord_flip() +
  theme_minimal() +
  labs(
    title = "Pemetaan Penggerak Harga Utama (Price Drivers)",
```

```
    subtitle = "Korelasi absolut terhadap valuasi properti",
    x = "Fitur Properti",
    y = "Koefisien Korelasi (Pearson)"
  ) +
  theme(
    legend.position = "none",
    panel.grid.major.y = element_blank(),
    plot.title = element_text(face = "bold", size = 14)
  )
```



Insight Bisnis: Berdasarkan nilai korelasi, variabel (`total_sqft`) dan (`overall_qual_num`) menunjukkan hubungan linear yang relatif lebih kuat terhadap (`sale_price`) dibandingkan variabel numerik lainnya. Hal ini menunjukkan bahwa kedua fitur tersebut berpotensi menjadi faktor penting dalam analisis harga properti.

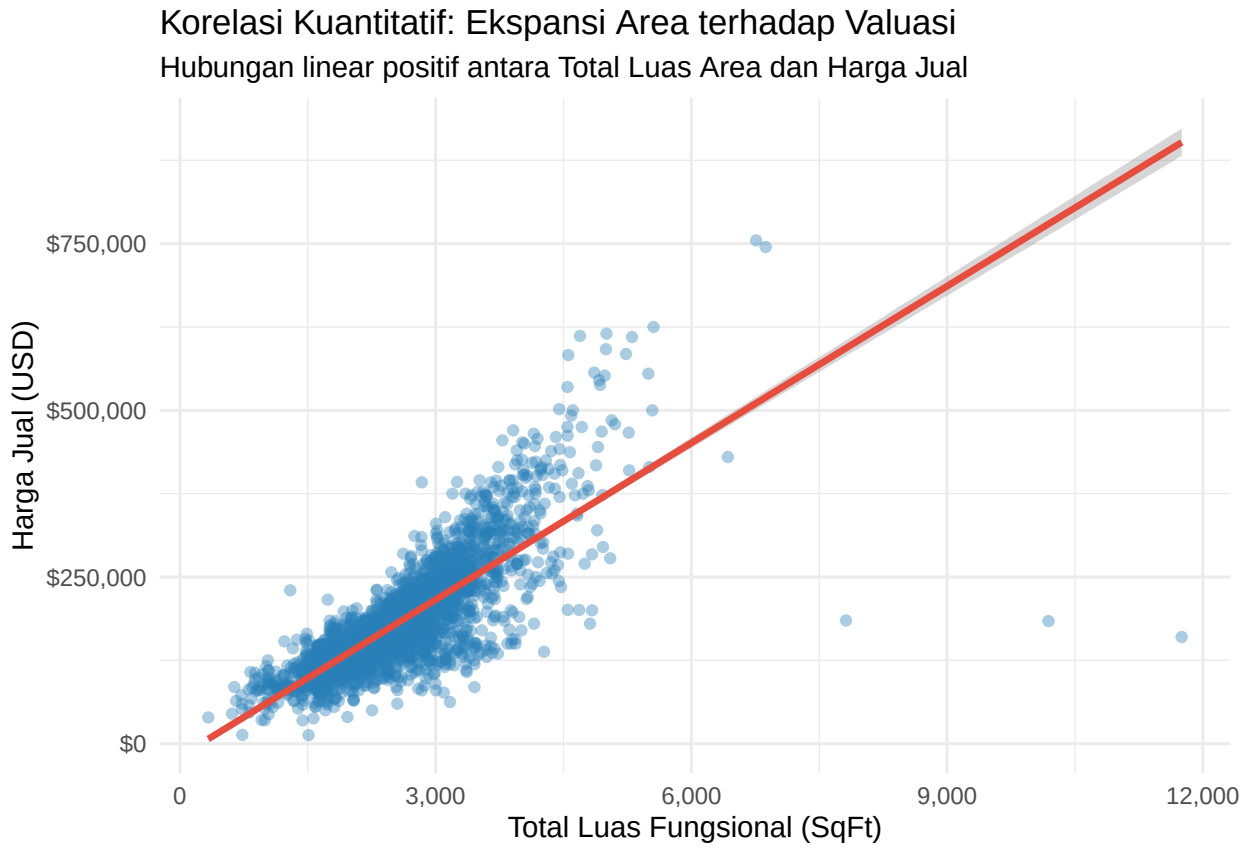
10. Hubungan Luas Rumah dan Harga Rumah

Evaluasi korelasi linear divisualisasikan menggunakan *Scatter Plot* untuk melihat seberapa konsisten harga naik seiring dengan bertambahnya luas properti. Garis tren regresi (*Line of Best Fit*) disematkan untuk memvalidasi arah pergerakan.

```
ggplot(ames_clean, aes(x = total_sqft, y = sale_price)) +
  geom_point(alpha = 0.4, color = "#2980B9") +
  geom_smooth(method = "lm", color = "#E74C3C", linewidth = 1.2, se = TRUE) +
  scale_y_continuous(labels = scales::dollar_format()) +
  scale_x_continuous(labels = scales::comma_format()) +
  theme_minimal() +
  labs(
```

```
    title = "Korelasi Kuantitatif: Ekspansi Area terhadap Valuasi",
    subtitle = "Hubungan linear positif antara Total Luas Area dan Harga Jual",
    x = "Total Luas Fungsional (SqFt)",
    y = "Harga Jual (USD)"
  )
```

```
## `geom_smooth()` using formula = 'y ~ x'
```



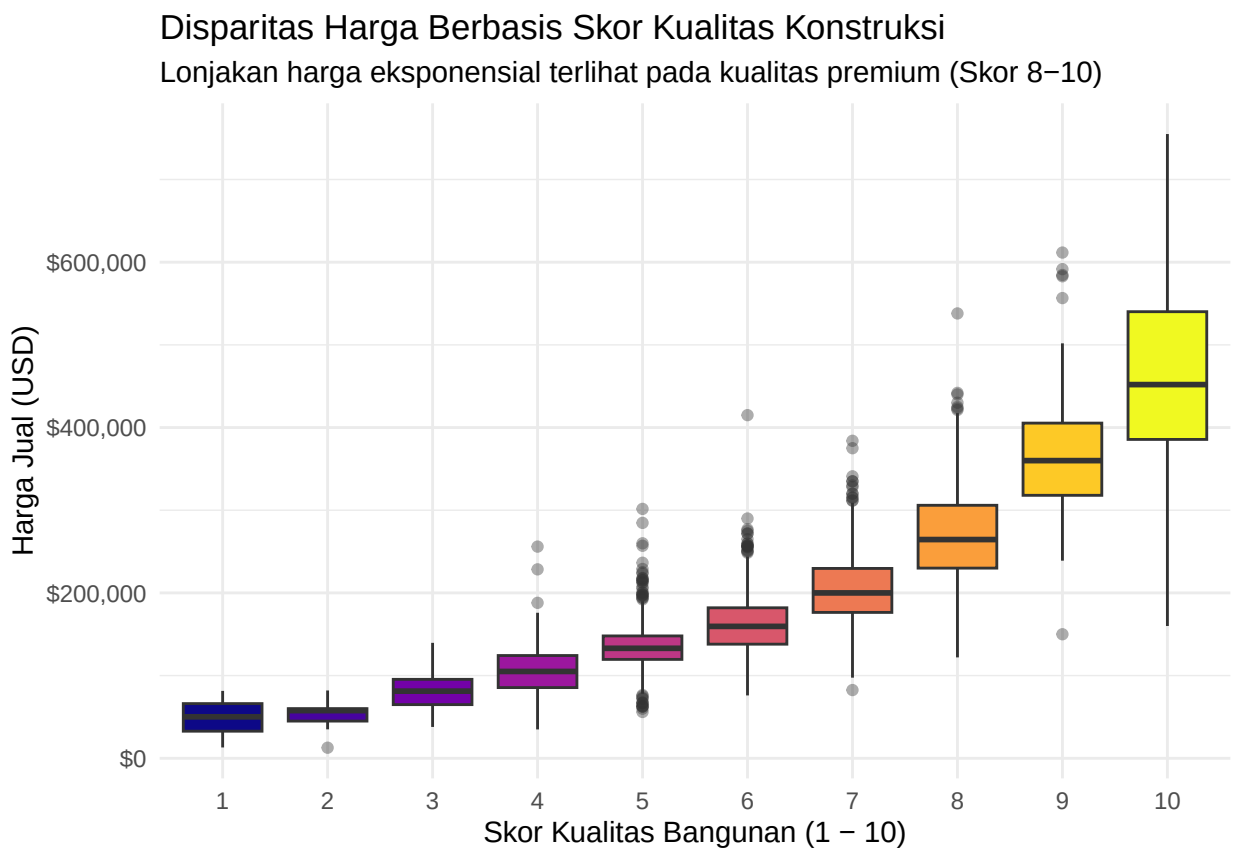
Insight Bisnis: Terlihat kecenderungan hubungan positif antara luas bangunan (`total_sqft`) dan harga jual. Namun, variasi harga yang meningkat pada luas bangunan besar menunjukkan bahwa faktor lain seperti kualitas dan lokasi juga dapat memengaruhi harga. Namun, terlihat penyebaran (*variance*) yang semakin melebar pada rentang area di atas 3,000 SqFt, menandakan bahwa untuk rumah-rumah raksasa, faktor lain (seperti lokasi atau kualitas material) mengambil alih kendali harga.

11. Harga Rumah Berdasarkan Kualitas Bangunan

Variabel Kualitas Bangunan (`overall_qual_num`) adalah metrik ordinal (bertingkat). Analisis komparasi distribusinya divisualisasikan menggunakan *Boxplot* bergradasi untuk melihat lonjakan nilai intrinsik properti di setiap tingkat kualitas.

```
ggplot(ames_clean, aes(x = factor(overall_qual_num), y = sale_price, fill = factor(overall_qual_num))) +
  geom_boxplot(show.legend = FALSE, outlier.alpha = 0.4) +
  scale_y_continuous(labels = scales::dollar_format()) +
  scale_fill_viridis_d(option = "C") +
  theme_minimal() +
```

```
  labs(
    title = "Disparitas Harga Berbasis Skor Kualitas Konstruksi",
    subtitle = "Lonjakan harga eksponensial terlihat pada kualitas premium (Skor 8-10)",
    x = "Skor Kualitas Bangunan (1 - 10)",
    y = "Harga Jual (USD)"
  )
```



Insight Bisnis: Hubungan antara kualitas bangunan dan harga menunjukkan pola peningkatan yang tidak sepenuhnya linear. Kenaikan skor kualitas tertentu terlihat memiliki perbedaan nilai jual yang lebih besar dibandingkan kenaikan pada tingkat kualitas yang lebih rendah. Menaikkan kualitas rumah dari skor 4 ke 5 hanya memberikan sedikit nilai tambah, tetapi melompat dari skor 8 ke 9 (Premium) akan menggelembungkan valuasi properti secara drastis.

12. Persiapan untuk Klastering (Standardisasi)

Unsupervised Learning (seperti algoritma K-Means) menghitung jarak spasial antar titik data (*Euclidean Distance*). Perbedaan skala numerik yang masif—misalnya `total_sqft` yang bernilai ribuan vs `overall_qual_num` yang hanya berskala 1-10—akan menyebabkan bias algoritma. Oleh karena itu, prosedur *Z-Score Scaling* (Standardisasi) dieksekusi agar semua fitur memiliki rata-rata 0 dan standar deviasi 1.

```
# Mengisolasi metrik utilitas fisik untuk segmentasi (Klastering)
cluster_data <- ames_clean %>%
  select(total_sqft, overall_qual_num, house_age, garage_area)
```

```r
# Standardisasi matematis
cluster_scaled <- scale(cluster_data)

# Verifikasi hasil transformasi
cat("Sampel matriks data pasca-standardisasi:\n")
```

```
## Sampel matriks data pasca-standardisasi:
```

```r
head(cluster_scaled, 3)
```

```
##      total_sqft overall_qual_num house_age garage_area
## [1,]  0.2298084      -0.06724223 0.4478462   0.2571790
## [2,] -0.9598795      -0.77594635 0.4148335   1.1958966
## [3,]  0.1329444      -0.06724223 0.5138717  -0.7465981
```

13. Menentukan Jumlah Cluster (Optimasi K: Elbow vs Silhouette)

Guna mengunci validitas jumlah segmen (K), dilakukan pendekatan dual-validation. Metode WSS (Elbow) digunakan untuk melihat penurunan varians secara global, sementara Metode Silhouette diaplikasikan untuk mengukur kualitas retensi spasial dan batas ketegasan antar-klaster.

```r
set.seed(42)

# 1. Grafik Elbow (WSS)
p1 <- fviz_nbclust(cluster_scaled, kmeans, method = "wss", linecolor = "#2980B9") +
  geom_vline(xintercept = 3, linetype = "dashed", color = "#E74C3C") +
  theme_minimal() +
  labs(title = "Elbow Method (Varians global)", x = "Jumlah Klaster (K)", y = "Total WSS")

# 2. Grafik Silhouette (Kerapatan Klaster)
p2 <- fviz_nbclust(cluster_scaled, kmeans, method = "silhouette", linecolor = "#2ECC71") +
  geom_vline(xintercept = 3, linetype = "dashed", color = "#E74C3C") +
  theme_minimal() +
  labs(title = "Silhouette Method (Kerapatan struktur)", x = "Jumlah Klaster (K)", y = "Average Silhoue
```

Menggabungkan kedua grafik secara horizontal

grid.arrange(p1, p2, ncol = 2) *Insight Analitik: Titik tekuk (“siku”) grafik menunjukkan perlambatan penurunan varians secara signifikan di area K=3. Berdasarkan hasil evaluasi Elbow dan Silhouette, jumlah cluster sebanyak 3 dipilih sebagai konfigurasi yang memberikan keseimbangan antara variasi internal dan struktur pemisahan antar kelompok.

14. Persiapan Klasifikasi (Target Engineering)

Algoritma *Decision Tree* atau Klasifikasi membutuhkan target kategorikal diskrit. Untuk menghindari bias model akibat fenomena *Class Imbalance* (data berat sebelah), ambang batas pemisahan kelas properti didefinisikan secara ekuilibrium menggunakan nilai Median. Variabel kontinu asal (`sale_price`) ditiadakan guna meredam insiden kebocoran data (*Target Leakage*).

14. Persiapan Klasifikasi (Target Engineering 3 Kelas)

Guna menghindari bias mayoritas, pembagian kelas properti didefinisikan ke dalam 3 segmen ekuilibrium (Low, Medium, High) menggunakan metode pemotongan Tertile (33.3%).

```
# Evaluasi batas Tertile
q33 <- quantile(ames_clean$sale_price, 0.3333)
q66 <- quantile(ames_clean$sale_price, 0.6667)

cat("Batas Low-Medium : $", format(q33, big.mark=","), "\n")
```

```
## Batas Low-Medium : $ 139,000
```

```
cat("Batas Medium-High: $", format(q66, big.mark=","), "\n\n")
```

```
## Batas Medium-High: $ 190,000
```

```
# Pembentukan Set Data Klasifikasi 3 Kelas & Pembersihan Outlier Kategori
ames_class <- ames_clean %>%
  # Membuang kategori langka untuk mencegah error "new levels" saat ML
  filter(kitchen_qual != "poor") %>%
  mutate(
    price_class = case_when(
      sale_price <= q33 ~ "low",
      sale_price > q33 & sale_price <= q66 ~ "medium",
      sale_price > q66 ~ "high"
    ),
    price_class = factor(price_class, levels = c("low", "medium", "high"))
  ) %>%
  select(-sale_price)

cat("Distribusi keseimbangan target Klasifikasi 3 Kelas:\n")
```

```
## Distribusi keseimbangan target Klasifikasi 3 Kelas:
```

```
table(ames_class$price_class)
```

```
##
##    low medium   high
##    980    980    969
```

3. Fase Pemodelan (Machine Learning)

Pada fase ini, data yang telah melalui proses sanitasi dan rekayasa fitur diuji menggunakan tiga paradigma algoritma *Machine Learning* yang berbeda. Pengujian melibatkan satu model *Unsupervised Learning* untuk segmentasi, dan dua model *Supervised Learning* untuk estimasi nilai kontinu serta klasifikasi kasta harga.

15. Model 1: Segmentasi Pasar (K-Means Clustering)

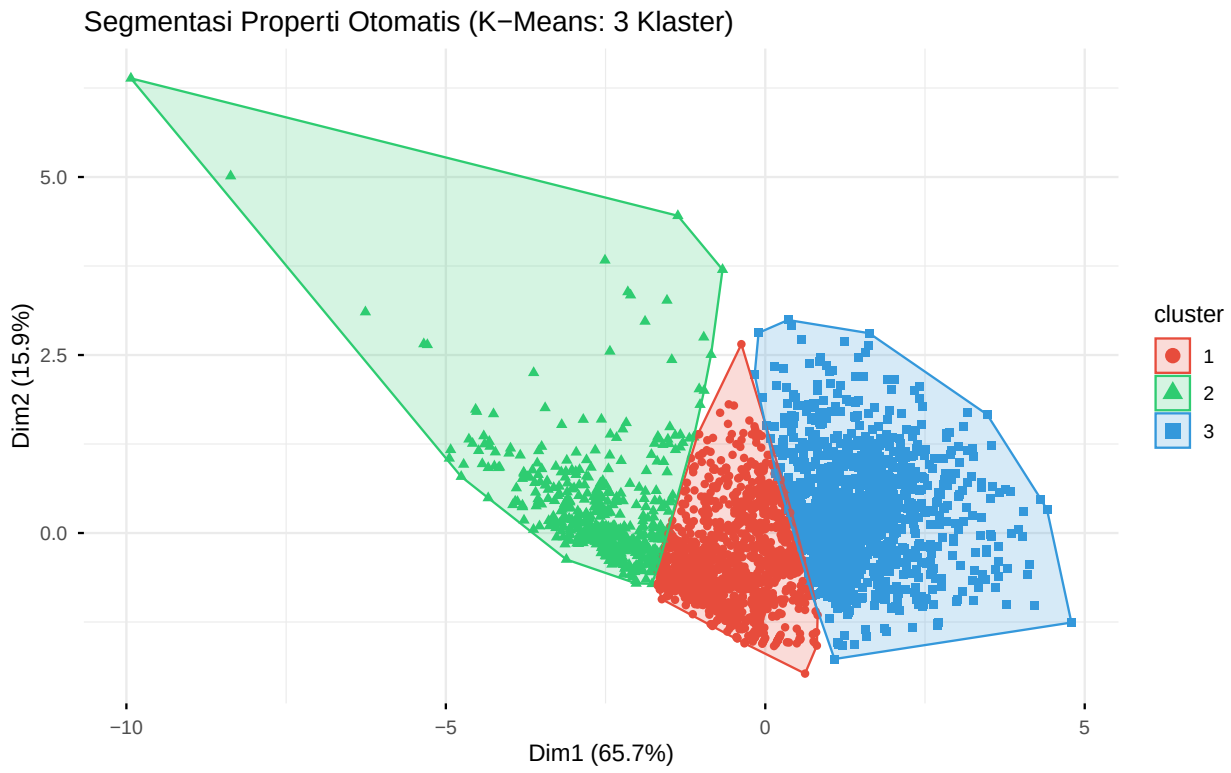
Algoritma K-Means digunakan sebagai perwakilan *Unsupervised Learning*. Model ini bertugas mengelompokkan seluruh portofolio properti secara objektif berdasarkan kemiripan karakteristik fisik tanpa melibatkan variabel harga (`sale_price`). Pendekatan ini mengeliminasi bias harga pasar dan murni menilai properti dari kapasitas utilitas strukturalnya.

```
# Fiksasi random state untuk reprodusibilitas hasil klastering
set.seed(42)



# Eksekusi K-Means menggunakan K=3 yang didukung oleh Elbow & Silhouette Method
kmeans_model <- kmeans(cluster_scaled, centers = 3, nstart = 25)

# Visualisasi sebaran klaster berbasis reduksi dimensi PCA 2D
fviz_cluster(kmeans_model, data = cluster_scaled,
             geom = "point", ellipse.type = "convex",
             ggtheme = theme_minimal(),
             main = "Segmentasi Properti Otomatis (K-Means: 3 Klaster)",
             palette = c("#E74C3C", "#2ECC71", "#3498DB"))
```




```
cluster_result <- ames_clean %>%
  mutate(
    Cluster = factor(kmeans_model$cluster)
  )
```

```r
# Profiling tiap cluster
cluster_profile <- cluster_result %>%
  group_by(Cluster) %>%
  summarise(
    Jumlah_Rumah = n(),
    Rata2_Harga = mean(sale_price),
    Rata2_Luas = mean(total_sqft),
    Rata2_Kualitas = mean(overall_qual_num),
    Rata2_Usia = mean(house_age)
  )

cluster_profile
```

```
## # A tibble: 3 x 6
##   Cluster Jumlah_Rumah Rata2_Harga Rata2_Luas Rata2_Kualitas Rata2_Usia
##   <fct>          <int>       <dbl>      <dbl>          <dbl>      <dbl>
## 1 1               1198     185331.      2591.           6.40      20.0
## 2 2                482     312750.      3726.           8.11       9.05
## 3 3               1250     125568.      2059.           5.02      62.7
```

Insight Analitik & Filosofi Model:

- **Mengapa K-Means?** Di industri *real estate*, tim bisnis (khususnya divisi *Marketing* dan pengembang) membutuhkan alat untuk mengelompokkan aset secara otomatis tanpa dipengaruhi oleh fluktuasi harga. K-Means memecahkan masalah ini dengan menghitung jarak spasial (*Euclidean Distance*) antar fitur fungsional yang sudah kita standardisasi.
- **Interpretasi Visual:** Visualisasi PCA menunjukkan adanya pemisahan relatif antar kelompok, meskipun beberapa area masih memiliki kedekatan karakteristik. Hal ini menunjukkan bahwa fitur yang digunakan mampu membentuk segmentasi berdasarkan kemiripan karakteristik properti.

Profiling Cluster

Profiling dan Interpretasi Cluster

Hasil clustering menggunakan algoritma K-Means membagi data rumah menjadi tiga kelompok berdasarkan kemiripan karakteristik properti. Setiap cluster kemudian dianalisis berdasarkan rata-rata harga jual, luas bangunan, kualitas rumah, dan fitur utama lainnya untuk memahami karakteristik masing-masing segmen.

Berdasarkan hasil profiling, diperoleh interpretasi sebagai berikut:

- **Cluster 1 (Segmen Menengah):**
  Cluster ini memiliki karakteristik rumah dengan nilai rata-rata harga, luas bangunan, dan kualitas yang berada pada tingkat menengah. Kelompok ini merepresentasikan rumah yang memiliki keseimbangan antara ukuran properti dan kualitas fasilitas.
- **Cluster 2 (Segmen Premium):**
  Cluster ini memiliki rata-rata harga jual, luas bangunan, dan kualitas rumah paling tinggi dibandingkan cluster lainnya. Kelompok ini menunjukkan karakteristik properti dengan spesifikasi yang lebih unggul dan dapat dikategorikan sebagai segmen premium.
- **Cluster 3 (Segmen Ekonomis):**
  Cluster ini memiliki rata-rata harga, luas bangunan, dan kualitas rumah yang lebih rendah dibandingkan cluster lain. Kelompok ini merepresentasikan properti dengan karakteristik yang lebih sederhana dan berada pada segmen ekonomis.

Hasil clustering menunjukkan bahwa algoritma K-Means mampu membentuk segmentasi properti berdasarkan pola karakteristik rumah tanpa menggunakan label harga secara langsung. Segmentasi ini dapat membantu memahami perbedaan profil properti dalam dataset Ames Housing. Hasil clustering menunjukkan bahwa fitur properti mampu membentuk kelompok rumah berdasarkan karakteristik yang serupa.

Simulasi Hasil Segmentasi Pasar (K-Means di Lapangan)

```
# Tambahkan label cluster ke data asli

set.seed(102)

# Menempelkan label klaster ke data asli untuk profiling bisnis
ames_clustered <- ames_clean %>%
  select(neighborhood, total_sqft, overall_qual_num, house_age) %>%
 mutate(
  Segmen_Pasar = case_when(
    kmeans_model$cluster == 1 ~ "Menengah",
    kmeans_model$cluster == 2 ~ "Premium",
    kmeans_model$cluster == 3 ~ "Ekonomis"
  )
)

# Pengambilan sampel acak lintas klaster
ames_clustered %>%
  sample_n(5) %>%
  knitr::kable(caption = "Simulasi Profiling Produk Hasil Segmentasi K-Means",
               col.names = c("Kawasan", "Luas Fungsional (SqFt)", "Skor Kualitas", "Usia Bangunan", "Lab
```

Table 1: Simulasi Profiling Produk Hasil Segmentasi K-Means

Kawasan	Luas Fungsional (SqFt)	Skor Kualitas	Usia Bangunan	Label Segmen
northwest_ames	2714	6	42	Menengah
crawford	1874	5	69	Ekonomis
old_town	1626	6	76	Ekonomis
north_ames	1728	4	36	Ekonomis
north_ames	2752	6	41	Menengah

Insight Operasional Bisnis: Melalui hasil segmentasi K-Means, setiap cluster dapat diterjemahkan menjadi kelompok pasar berdasarkan karakteristik properti. Informasi ini dapat membantu penyusunan strategi pemasaran yang lebih sesuai dengan profil rumah.

- **Klaster 1 (Menengah/Standard):** Memiliki karakteristik rumah dengan harga, luas bangunan, dan kualitas pada tingkat menengah. Segmen ini dapat merepresentasikan pasar dengan kebutuhan hunian yang seimbang antara ukuran, kualitas, dan harga.
- **Klaster 2 (Premium/High-End):** Memiliki rata-rata luas bangunan, kualitas, dan harga tertinggi dibandingkan cluster lainnya. Segmen ini merepresentasikan properti dengan spesifikasi lebih unggul yang berpotensi menyasar konsumen dengan daya beli lebih tinggi.

- **Klaster 3 (Ekonomis/Klasik):** Memiliki harga dan kualitas rata-rata paling rendah serta usia bangunan paling tinggi. Segmen ini dapat dikaitkan dengan rumah yang lebih terjangkau atau properti yang berpotensi dikembangkan melalui renovasi.

Hasil segmentasi menunjukkan bahwa K-Means mampu mengelompokkan properti berdasarkan kemiripan karakteristik tanpa menggunakan label harga secara langsung.

---

16. Model 2: Prediksi Harga Jual (Multiple Linear Regression)

Algoritma Regresi Linear Multivariat digunakan untuk menyelesaikan masalah *Supervised Learning* berskala kontinu. Model ini dilatih untuk menemukan bobot kontribusi linier dari setiap fitur prediktor terhadap variabel target harga (`sale_price`).

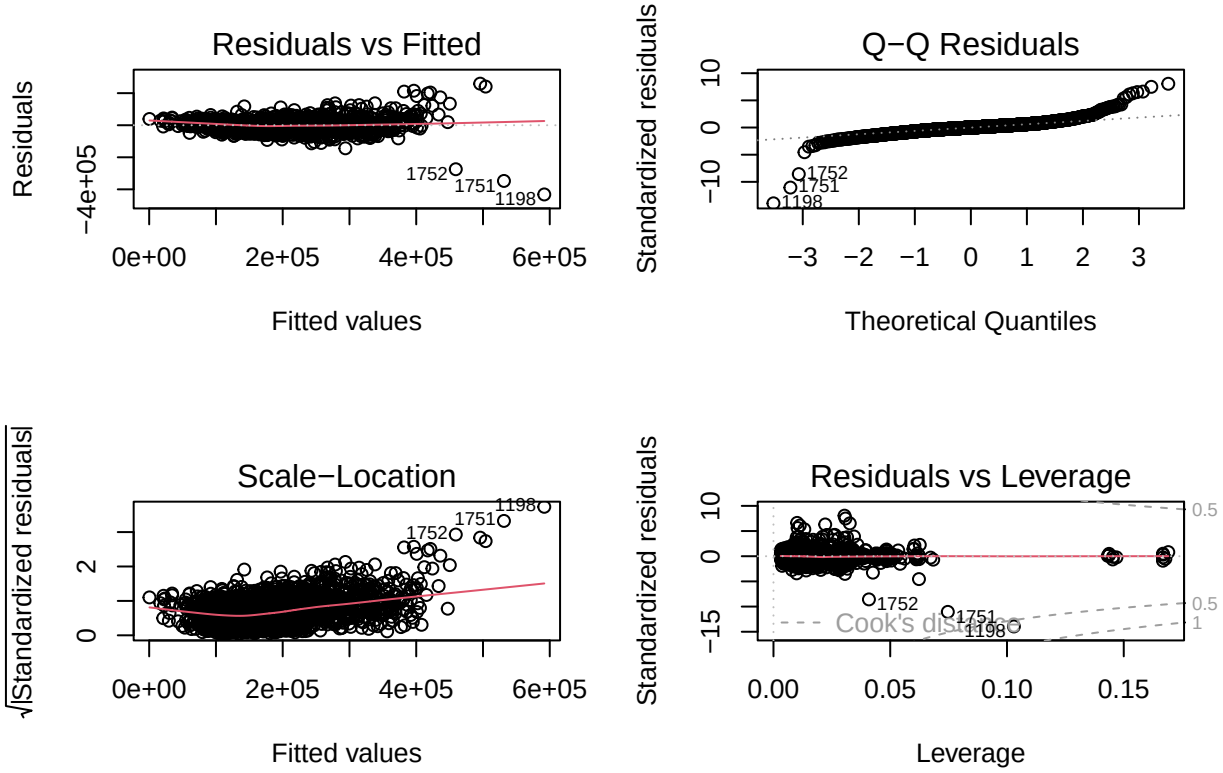
```
# Pembersihan kategori langka 'poor' pada kualitas dapur untuk menjamin stabilitas split data
ames_reg <- ames_clean %>% filter(kitchen_qual != "poor")

# Data Splitting (80% Data Latih untuk belajar, 20% Data Uji untuk ujian)
set.seed(42)
train_idx <- createDataPartition(ames_reg$sale_price, p = 0.8, list = FALSE)
train_reg <- ames_reg[train_idx, ]
test_reg  <- ames_reg[-train_idx, ]

# Pelatihan Model Regresi
lm_model <- lm(sale_price ~ ., data = train_reg)

par(mfrow=c(2,2))
plot(lm_model)
```

```
## Warning: not plotting observations with leverage one:
##   1818, 2236
```




```r
# Pengujian Model (Prediksi terhadap data baru yang belum pernah dilihat mesin)
pred_reg <- predict(lm_model, test_reg)

# Kalkulasi Tri-Metrik Evaluasi Komprehensif
# Kalkulasi Tri-Metrik Evaluasi Komprehensif

mae_val  <- Metrics::mae(test_reg$sale_price, pred_reg)

rmse_val <- Metrics::rmse(test_reg$sale_price, pred_reg)


# R-Squared data training
r2_train <- summary(lm_model)$r.squared


# Prediksi data testing
lm_pred <- predict(
  lm_model,
  newdata = test_reg
)


# R-Squared data testing
test_r2 <- cor(
  test_reg$sale_price,
  lm_pred
```

```
)^2


# RMSE dalam persentase
mean_price <- mean(test_reg$sale_price)

rmse_percentage <-
  rmse_val / mean_price * 100

cat("=====================================================\n")
```

```
## =====================================================
```

```
cat("MATRIKS EVALUASI KOMPREHENSIF REGRESI LINEAR\n")
```

```
## MATRIKS EVALUASI KOMPREHENSIF REGRESI LINEAR
```

```
cat("=====================================================\n")
```

```
## =====================================================
```

```
cat("Mean Absolute Error (MAE)       : $", format(round(mae_val, 2), big.mark=","), "\n")
```

```
## Mean Absolute Error (MAE)       : $ 18,445.52
```

```
cat("Root Mean Squared Error (RMSE)  : $", format(round(rmse_val, 2), big.mark=","), "\n")
```

```
## Root Mean Squared Error (RMSE)  : $ 27,272.25
```

```
cat(
"Train R-Squared                : ",
round(r2_train * 100,2),
"%\n"
)
```

```
## Train R-Squared                :  83.54 %
```

```
cat(
"Test R-Squared                 : ",
round(test_r2 * 100,2),
"%\n"
)
```

```
## Test R-Squared                 :  88.33 %
```

```
cat(
"RMSE relatif terhadap harga    : ",
round(rmse_percentage,2),
"%\n"
)
```

```
## RMSE relatif terhadap harga    :  15.07 %
```

```
cat("================================================\n")
```

```
## ================================================
```

Insight Analitik & Filosofi Model Regresi Linear dipilih karena mampu memberikan interpretasi yang jelas mengenai hubungan antara fitur yang digunakan dengan harga jual rumah. Model ini membantu melihat bagaimana perubahan pada karakteristik rumah dapat berkaitan dengan perubahan harga.

Evaluasi Performa Model Regresi Linear

Berdasarkan hasil pengujian pada data testing, model menghasilkan nilai Test R-Squared sebesar 88,33%. Nilai ini menunjukkan bahwa fitur-fitur yang digunakan dalam model mampu menjelaskan sebagian besar variasi harga rumah pada data yang belum pernah dilihat sebelumnya.

Nilai MAE sebesar $18.445,52 menunjukkan rata-rata selisih antara harga aktual dan hasil prediksi model. Sementara itu, RMSE sebesar $27.272,25 memberikan gambaran bahwa terdapat beberapa prediksi dengan error yang lebih besar karena RMSE memberikan penalti lebih tinggi terhadap kesalahan besar.

Jika dibandingkan dengan rata-rata harga rumah, tingkat error model berada pada kisaran 15,07%. Hasil ini menunjukkan bahwa model memiliki kemampuan prediksi yang cukup baik, meskipun masih terdapat faktor lain di luar fitur yang digunakan yang dapat memengaruhi harga rumah.

Performa ini menunjukkan kemampuan generalisasi yang baik pada data uji, tetapi hasil prediksi tetap dipengaruhi oleh faktor lain di luar fitur yang digunakan.

Simulasi Prediksi di Lapangan (Real-World Inference)

```
set.seed(101)
sample_houses <- test_reg %>% sample_n(5)
sample_predictions <- predict(lm_model, sample_houses)

real_world_test <- data.frame(
  Kawasan = sample_houses$neighborhood,
  Luas_SqFt = sample_houses$total_sqft,
  Kualitas = sample_houses$overall_qual_num,
  Harga_Asli = sample_houses$sale_price,
  Tebakan_Model = round(sample_predictions, 0),
  Batas_Bawah = round(sample_predictions - rmse_val, 0),
  Batas_Atas = round(sample_predictions + rmse_val, 0)
) %>%
  mutate(Status = ifelse(Harga_Asli >= Batas_Bawah & Harga_Asli <= Batas_Atas,
                         "Akurat (Dalam Rentang)", "Meleset (Outlier)"))

knitr::kable(real_world_test, format.args = list(big.mark = ","),
             caption = "Simulasi Penggunaan Model Regresi Linear pada Skenario Riil")
```

Table 2: Simulasi Penggunaan Model Regresi Linear pada Skenario Riil

Kawasan	Luas_Sqft	Kualitas	Harga_Asli	Tebakan_Model	Batas_Bawah	Batas_Atas	Status
south_and_west_of_iowa_state_university	4,835	6	200,000	202,244	174,972	229,516	Akurat (Dalam Rentang)
gilbert	3,052	7	214,000	222,601	195,329	249,873	Akurat (Dalam Rentang)
northridge_heights	2,734	7	192,000	237,814	210,542	265,086	Meleset (Outlier)
mitchell	2,871	4	168,000	185,022	157,750	212,294	Akurat (Dalam Rentang)
northridge	3,723	7	290,000	302,736	275,464	330,009	Akurat (Dalam Rentang)

Insight Operasional Bisnis: Tabel simulasi di atas memperlihatkan bagaimana nilai RMSE diubah menjadi *Value Creation* di dunia bisnis. Batas Bawah dan Batas Atas yang dibentuk dari ± RMSE berfungsi sebagai **rentang toleransi harga pasar (Margin of Error)**. Jika agen properti ingin melakukan negosiasi dengan calon pembeli, rentang inilah yang dijadikan acuan legal agar perusahaan tidak mengalami kerugian akibat salah taksir.

---

17. Model 3: Klasifikasi Kelas Harga (Decision Tree)

Model terakhir menerapkan algoritma *Decision Tree* (Classification) untuk memecahkan masalah *Supervised Learning* kategorikal. Model ini bertugas memilah properti ke dalam tiga kasta kelas harga secara seimbang (Low, Medium, High) berdasarkan aturan logis (*rules*) pecahan parametrik fisik rumah.

```
# Data Splitting berdasarkan proporsi target 3-Kelas
set.seed(42)
train_class_idx <- createDataPartition(ames_class$price_class, p = 0.8, list = FALSE)
train_class <- ames_class[train_class_idx, ]
test_class  <- ames_class[-train_class_idx, ]

table(
ames_class$price_class
)
```

```
##
##    low medium   high
##    980    980    969
```

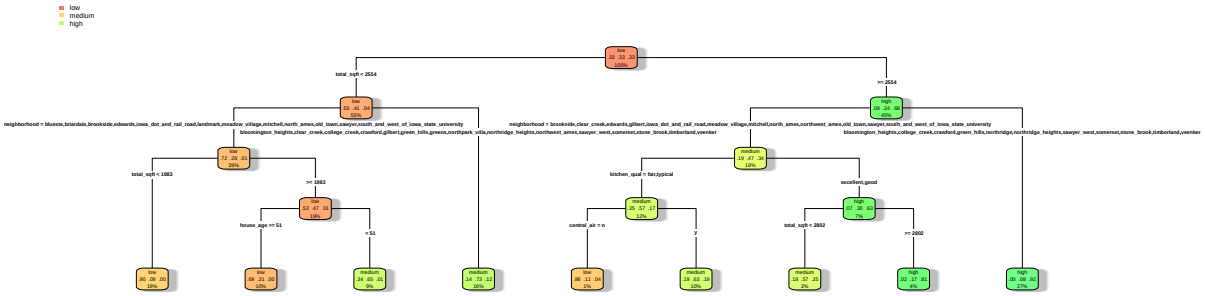
```
prop.table(
table(
ames_class$price_class
)
)
```

```
##
##       low    medium      high
## 0.3345852 0.3345852 0.3308296
```

```
# Pelatihan Model Pohon Keputusan (CART)
tree_model <- rpart(price_class ~ ., data = train_class, method = "class", cp = 0.01)

# Visualisasi Struktur Anatomi Pohon Keputusan
rpart.plot(tree_model, main = "Struktur Aturan Keputusan Klasifikasi Kasta Harga",
           type = 4, extra = 104, box.palette = "RdYlGn", shadow.col = "gray")
```

Struktur Aturan Keputusan Klasifikasi Kasta Harga




```
# Prediksi Kelas Kategori pada Data Uji
pred_class <- predict(tree_model, test_class, type = "class")

# Kalkulasi Validasi Menggunakan Confusion Matrix Lengkap
conf_matrix <- confusionMatrix(pred_class, test_class$price_class)

# PERBAIKAN: Mencetak Struktur Confusion Matrix Utuh ke Layar Laporan
print(conf_matrix)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction low medium high
##     low    155     26    0
##     medium  39    153   36
##     high     2     17  157
##
## Overall Statistics
##
##                Accuracy : 0.7949
##                  95% CI : (0.7598, 0.8269)
```

```
##     No Information Rate : 0.335
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.6922
##
##  Mcnemar's Test P-Value : 0.009697
##
## Statistics by Class:
##
##                      Class: low Class: medium Class: high
## Sensitivity              0.7908        0.7806      0.8135
## Specificity              0.9332        0.8072      0.9515
## Pos Pred Value           0.8564        0.6711      0.8920
## Neg Pred Value           0.8985        0.8796      0.9120
## Prevalence               0.3350        0.3350      0.3299
## Detection Rate           0.2650        0.2615      0.2684
## Detection Prevalence     0.3094        0.3897      0.3009
## Balanced Accuracy        0.8620        0.7939      0.8825
```

Insight Analitik & Filosofi Model:

- **Mengapa Decision Tree?** Berbeda dengan Regresi yang bersifat abu-abu (*Black-Box* matematika), *Decision Tree* adalah model *White-Box* yang Decision Tree memiliki tingkat interpretabilitas yang tinggi karena menghasilkan aturan keputusan berbentuk percabangan yang relatif mudah dipahami. Model ini meniru cara berpikir logis manusia dengan membuat percabangan "Jika-Maka" (*If-Else*), sehingga sangat mudah dipresentasikan kepada jajaran direksi non-teknis.
- **Konvergensi Temuan dengan EDA:** Perhatikan struktur pohon keputusan di atas. Algoritma secara otomatis meletakkan variabel `total_sqft` (Luas Bangunan) dan `overall_qual_num` (Skor Kualitas) di posisi paling puncak (*root node* / cabang utama). Hal ini memberikanmemberikan indikasi bahwa kedua fitur tersebut memiliki kontribusi penting dalam proses pengambilan keputusan model pada dataset ini. kasta nilai properti di kota Ames, selaras dengan visualisasi korelasi pada Tahap EDA Poin 9.
- **Evaluasi Confusion Matrix 3 Kelas:** Hasil matriks kebingungan (*Confusion Matrix*) di atas memaparkan tabel kontingensi antara kelas aktual vs tebakan mesin. Model mampu mengklasifikasikan kelas *Low*, *Medium*, dan *High* dengan tingkat akurasi yang cukup baik dengan distribusi kelas yang seimbang Nilai diagonal utama yang dominan menunjukkan bahwa kesalahan tebak mayoritas hanya bergeser ke kelas tetangga terdekat (misal: rumah *Medium* salah tebak sebagai *Low* atau *High*), dan hampir tidak ada kesalahan ekstrem di mana rumah kelas *Low* langsung melompat salah tebak menjadi kelas *High*.

Simulasi Klasifikasi Kelas Properti (Decision Tree di Lapangan)

```r
set.seed(105)

# Ambil 5 data contoh dari test
sample_class <- test_class %>%
  sample_n(5)


# Prediksi seluruh test untuk evaluasi
```

```r
tree_preds <- predict(
  tree_model,
  newdata = test_class,
  type = "class"
)


# Evaluasi confusion matrix
confusionMatrix(
  factor(tree_preds),
  factor(test_class$price_class)
)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction low medium high
##     low    155     26    0
##     medium  39    153   36
##     high     2     17  157
##
## Overall Statistics
##
##                Accuracy : 0.7949
##                  95% CI : (0.7598, 0.8269)
##     No Information Rate : 0.335
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.6922
##
##  Mcnemar's Test P-Value : 0.009697
##
## Statistics by Class:
##
##                      Class: low Class: medium Class: high
## Sensitivity              0.7908        0.7806      0.8135
## Specificity              0.9332        0.8072      0.9515
## Pos Pred Value           0.8564        0.6711      0.8920
## Neg Pred Value           0.8985        0.8796      0.9120
## Prevalence               0.3350        0.3350      0.3299
## Detection Rate           0.2650        0.2615      0.2684
## Detection Prevalence     0.3094        0.3897      0.3009
## Balanced Accuracy        0.8620        0.7939      0.8825
```

```r
# Prediksi khusus 5 sampel
sample_preds <- predict(
  tree_model,
  newdata = sample_class,
  type = "class"
)


# Tabel simulasi
```

```r
data.frame(
  Kawasan = sample_class$neighborhood,
  Luas_SqFt = sample_class$total_sqft,
  Kualitas = sample_class$overall_qual_num,
  Kelas_Asli = str_to_title(sample_class$price_class),
  Tebakan_Mesin = str_to_title(sample_preds)
) %>%
  mutate(
    Status = ifelse(
      Kelas_Asli == Tebakan_Mesin,
      "Tepat",
      "Meleset"
    )
  ) %>%
  knitr::kable(
    caption = "Simulasi Pengujian Klasifikasi Otomatis pada Data Riil"
  )
```

Table 3: Simulasi Pengujian Klasifikasi Otomatis pada Data Riil

Kawasan	Luas_SqFt	Kualitas	Kelas_Asli	Tebakan_Mesin	Status
edwards	1152	4	Low	Low	Tepat
old_town	1980	5	Low	Low	Tepat
northwest_ames	3717	7	High	Medium	Meleset
edwards	2313	4	Low	Low	Tepat
stone_brook	2560	8	High	High	Tepat

Insight Operasional Bisnis: Simulasi ini membuktikan kecepatan operasional algoritma. Hanya dengan memasukkan parameter luas dan kualitas, sistem aplikasi masa depan dapat secara instan memasukkan rumah baru ke dalam filter kategori "Ekonomis (Low)", "Standar (Medium)", atau "Premium (High)". Keberhasilan simulasi akhir ini menunjukkan bahwa rangkaian analisis data mining telah berhasil diterapkan pada dataset Ames Housing dan dapat menjadi dasar untuk pengembangan model lebih lanjut.

4. Kesimpulan & Insight Global (Executive Summary)

Sebagai penutup dari proyek *Data Mining* terpadu pada dataset Ames Housing, bagian ini merangkum seluruh temuan analitis dari tahap eksplorasi data (EDA), hasil pemodelan prediktif, serta segmentasi properti menggunakan metode *machine learning*.

1. Sintesis Temuan EDA dan Hasil Pemodelan

Analisis menunjukkan adanya keselarasan antara hasil eksplorasi data dengan pola yang ditemukan oleh model *machine learning*.

- Pada tahap EDA, analisis korelasi menunjukkan bahwa luas bangunan fungsional total (`total_sqft`) dan skor kualitas rumah (`overall_qual_num`) memiliki hubungan yang kuat terhadap harga jual rumah. Kedua karakteristik tersebut menunjukkan perbedaan yang cukup jelas pada berbagai kategori harga properti.

- Temuan tersebut diperkuat oleh hasil Model Decision Tree, di mana algoritma secara otomatis memilih fitur seperti `total_sqft` dan `overall_qual_num` sebagai beberapa percabangan awal (*root & split nodes*) dalam proses klasifikasi kelas harga rumah (Low, Medium, High).
- Secara keseluruhan, hasil analisis menunjukkan bahwa karakteristik fisik rumah, terutama luas bangunan dan kualitas properti, menjadi aspek penting dalam memahami pola harga pada dataset Ames Housing.

---

2. Evaluasi Tiga Model Machine Learning

Ketiga model digunakan untuk menjawab tujuan analisis yang berbeda, yaitu segmentasi karakteristik properti, prediksi harga, dan klasifikasi kelas harga.

1. **K-Means Clustering (Segmentasi Properti):**
   K-Means digunakan untuk mengelompokkan rumah berdasarkan kemiripan karakteristik tanpa menggunakan label harga secara langsung. Hasil profiling membentuk tiga segmen properti, yaitu segmen ekonomis, menengah, dan premium berdasarkan perbedaan rata-rata harga, luas bangunan, kualitas, dan usia rumah.
2. **Multiple Linear Regression (Prediksi Harga):**
   Model regresi linear digunakan untuk memperkirakan harga rumah secara numerik. Model menghasilkan **Test R-Squared sebesar 88,33% dengan nilai RMSE sekitar $27.272**. Hasil tersebut menunjukkan bahwa fitur-fitur yang digunakan mampu menjelaskan sebagian besar variasi harga pada data pengujian. Nilai RMSE memberikan gambaran rata-rata besarnya kesalahan prediksi model sehingga dapat digunakan untuk memahami tingkat ketidakpastian hasil prediksi.
3. **Decision Tree (Klasifikasi Kelas Harga):**
   Decision Tree digunakan untuk mengelompokkan rumah ke dalam tiga kategori harga, yaitu Low, Medium, dan High. Model menghasilkan aturan keputusan berbentuk percabangan sehingga lebih mudah diinterpretasikan. Berdasarkan evaluasi *Confusion Matrix*, model mampu melakukan klasifikasi dengan tingkat akurasi 79,49% dan nilai Kappa 0,69.

---

3. Insight dan Implikasi Analisis

Berdasarkan seluruh hasil analisis, terdapat beberapa insight utama yang diperoleh:

- **Faktor yang Berhubungan dengan Harga Rumah:**
  Luas bangunan (`total_sqft`) dan kualitas rumah (`overall_qual_num`) merupakan karakteristik yang memiliki hubungan kuat terhadap harga jual rumah pada dataset Ames Housing. Faktor tersebut dapat menjadi pertimbangan penting dalam memahami pola nilai properti.
- **Kemampuan Prediksi Harga Rumah:**
  Model regresi linear menunjukkan bahwa pendekatan berbasis fitur properti mampu menghasilkan estimasi harga dengan performa yang baik pada data pengujian. Meskipun demikian, hasil prediksi tetap dipengaruhi oleh karakteristik lain di luar fitur yang digunakan.
- **Segmentasi Rumah Berdasarkan Karakteristik:**
  Metode K-Means berhasil membentuk kelompok rumah berdasarkan kemiripan karakteristik. Segmentasi ini membantu melihat perbedaan profil properti mulai dari segmen ekonomis, menengah, hingga premium.

Laporan ini menunjukkan bahwa integrasi preprocessing, feature engineering, regression, classification, dan clustering dapat digunakan untuk memperoleh insight mengenai pola harga, prediksi nilai rumah, serta segmentasi properti pada dataset Ames Housing.